

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-xxxx-xxxx

**Rozšířená šablóna záverečnej práce na FEI STU
v Bratislave v systéme $\text{\LaTeX}$**

Bakalárska práca

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-xxxx-xxxx

**Rozšířená šablóna záverečnej práce na FEI STU
v Bratislave v systéme $\text{\LaTeX}$**

Bakalárska práca

Študijný program:	Aplikovaná informatika
Študijný odbor:	Informatika
Školiace pracovisko:	Ústav multimediálnych informačných a komunikačných technológií
Školiteľ:	Ing. Marek Vančo, PhD.

Podakovanie

Abstrakt

Kľúčové slová

záverečná práca, šablóna, L^AT_EX, formátovanie textu, citácie

Abstract

Keywords

Final thesis, template, L^AT_EX, text formatting, citations

Obsah

Úvod	8
1 Súčasný stav	9
1.1 Klasické metódy extrakcie	9
1.2 Konštrukcia KG	9
1.3 Vyhľadávanie nad grafmi	9
1.4 LLM v právnej doméne	9
2 Analýza problému a návrh systému	10
2.1 Charakteristika slovenských právnych dokumentov	10
2.2 Ontológia pre právnu doménu	10
2.3 Celková architektúra	10
2.4 Použité technológie	10
3 Spracovanie dokumentov	11
3.1 Predspracovanie	11
3.1.1 Detekcia rozloženia	11
3.1.2 Extrakcia tabuliek	11
3.2 Trojkroková extrakcia	12
3.2.1 Detekcia v otvorenej doméne	12
3.2.2 Úprava a spresnenie schémy	12
3.2.3 Schémou riadená extrakcia	12
3.3 Vkladanie do databázy	12
4 Vyhľadávanie a odpovedanie	13
4.1 Segmentácia otázky	13
4.2 Vyhľadávanie v grafe	13
4.3 Generovanie odpovede	13
5 Experimenty a vyhodnotenie	14
5.1 Testovanie otázky nad slovenským zákonom	14
5.2 Metriky: presnosť, úplnosť a uzemnenie	14
5.3 Porovnanie s klasickým RAG	14
5.4 Limity a budúca práca	14
Záver	15
Literatúra	16

Použitie nástrojov umelej inteligencie	16
--	----

Zoznam značiek a skratiek

Úvod

1 Súčasný stav

1.1 Klasické metódy extrakcie

1.2 Konštrukcia KG

1.3 Vyhľadávanie nad grafmi

1.4 LLM v právnej doméne

2 Analýza problému a návrh systému

2.1 Charakteristika slovenských právnych dokumentov


2.2 Ontológia pre právnu doménu

2.3 Celková architektúra

2.4 Použité technológie

3 Spracovanie dokumentov

Spracovanie transformuje PDF dokument Slovenského právneho odvetvia z neštruktúrovaného textu na štruktúrované dáta, ktoré sa uložia v znalostnom grafe (KG). Je to súvislá troj-kroková postupnosť: predspracovanie, extrakcia a vloženie do databázy. Tento tok dát je znázornený na obrázku č.1.



Obr. 1: Graf popisujúci spracovanie.

3.1 Predspracovanie

Čisté spracovanie PDF dokumentu nie je dostačujúce pre legislatívne dokumenty. Napríklad tabuľky, ktoré sú nositeľmi dôležitých, opisných a rozvíjajúcich vlastností, ako napríklad v zákone 222/2004 Z. z. [1] na strane 159, kde je kapitola/číselný znak spoločného colného sadzobníka a k nemu podliehajúci opis tovaru. Dokonca, sa táto tabuľka rozkladá na viacero strán. Pri čítaní tabuľky, ako reťazca by sa tieto informácie roztrúsili a zničil by sa tak kontext celej tabuľky. Vzorce sa taktiež vyskytujú naprieč dokumentom (str. 149) a v PDF dokumente su uchované ako obrázky - nástroj na čítanie textu z dokumentu by tento obrázok nerozpoznal a nenašiel.

3.1.1 Detekcia rozloženia

V tomto kroku sa každá strana dokumentu konvertuje na obrázok s rozlíšením 200 DPI. Aplikuje sa DocLayout-YOLO model, ktorý prejde a zdetekuje rozloženie každej strany. Tento detektor je nakonfigurovaný aby rozoznal päť cieľových tried: tabuľka, obrázok, diagram, izolovaný vzorec a popis vzorca. Detekcie s istotou pod 0,3 sú zahodené. Pre každú nájdenú detekciu, naväzujúci box je vystrihnutý z obrázku stránky a uložený ako bezstratový PNG súbor. Všetky susedné obrázky na základe strany (ak rozdiel strán je menší ako 2) sú zoskupené, aby tabuľky, ktoré sa rozliehajú na viacero strán, boli pri sebe ako jeden logický celok.

3.1.2 Extrakcia tabuliek

Každá skupina tabuliek je spracovaná v dvoch krokoch. Prvý krok, optický schopný Gemini model, prijme všetky orezané obrázky skupiny spoločne s system promptom, ktorý nariaďuje aby bol výstup tabuľka v podobe HTML. Tento prompt zakazuje sumarizáciu tabuľky a nariaďuje aby model zachoval doslovný text bunky. Druhý krok,

výsledný HTML výstup je poskytnutý ďalšiemu LLM volaniu, kde tento krát ma model za úlohu transformovať tabuľu do hierarchickej podoby vrcholov a vzťahov: tabuľka je označená ako koreňový vrchol, bunky každého riadku prvého stĺpca ako rodič, a potomok pre každú ďalšiu bunku daného riadku. Je to cesta ako zachovať význam tabuľky v znalostnom grafe. Vnútorne strany viac-stranovej tabuľky sú vyradené zo zoznamu strán PDF dokumentu, pre neskoršiu extrakciu aby sa predišlo duplicitám rovnakej informácie.

3.2 Trojkroková extrakcia

3.2.1 Detekcia v otvorenej doméne

3.2.2 Úprava a spresnenie schémy

3.2.3 Schémou riadená extrakcia

3.3 Vkladanie do databázy

4 Vyhľadávanie a odpovedanie

4.1 Segmentácia otázky

4.2 Vyhľadávanie v grafe

4.3 Generovanie odpovede

5 Experimenty a vyhodnotenie

5.1 Testovanie otázky nad slovenským zákonom

5.2 Metriky: presnosť, úplnosť a uzemnenie

5.3 Porovnanie s klasickým RAG

5.4 Limity a budúca práca

Záver

Literatúra

1. MINISTRY OF JUSTICE OF THE SLOVAK REPUBLIC. *Slov-Lex: Legal and Information Portal* [online]. Ministerstvo spravodlivosti Slovenskej republiky [cit. 2026-04-20]. Dostupné z: <https://www.slov-lex.sk/>.

Použitie nástrojov umelej inteligencie